期中進度報告 (Progress Check)

自然災害嚴重度預測 (Natural Disaster Severity Prediction)

第 5 組 (Group 5)
Hsin-Yu Chen, Wei-Hsin Hung, Sky Shih-Kai Hong

2026 年 5 月 21 日

任務與數據集

預測每個地區在 91 天測試期之後**未來五週**的旱災嚴重程度。

屬性	數值
預測地區數量	2,248
訓練集總資料筆數	12,319,040
可用 weekly label rows	1,746,696
每個地區的測試天數	91
氣象特徵數量	14

評估指標：**MAE (平均絕對誤差)**，越低越好。

數據觀察與痛點

目標值 `score` 是以「週」為單位，但氣象資料是以「日」為單位。

- 每週約有 **6 天的 score 是 NaN**，標籤相對稀疏。
- 核心難題：將**每日天氣訊號**對齊到**每週旱災嚴重度**。
- 測試集 91 天完全沒有真實 `score`，不能直接使用近期分數。
- 因此任何 score-history 特徵都必須處理 train/test discrepancy。

目前的模型架構 (Pipeline)

目前已整理成可重現的 **Direct Horizon Forecasting Pipeline**。

1. 從天氣、日曆、climatology/anomaly 建立時間序列特徵。
2. 加入乾旱領域特徵，如 drought index 與 dryness index。
3. 針對未來 5 週，分別訓練獨立 horizon model。
4. 支援 LightGBM、XGBoost、Ensemble 與 versioned experiments。

特徵工程 (Feature Engineering)

目前模型輸入包含多種特徵 profile，可在準確率與記憶體間取捨：

- **天氣動態**：lags、rolling mean/std、EWM。
- **時間訊號**：month、week、seasonal cyclic encoding。
- **領域特徵**：drought index、dryness index、dewpoint / wetbulb spread。
- **Gap-aware score history**：只使用 91 天 blind gap 之前的歷史分數。
- **Profiles**：`micro`、`lean`、`full`；目前最新完整 run 使用 `lean`。

直接多步預測 (Direct Multi-Step Forecasting)

針對 `week1` 到 `week5` 分別訓練 5 個獨立模型，避免遞迴式誤差累積。

驗證策略 (Validation Strategy)

已從單一 holdout 擴充到 **rolling-origin validation**，用多個 forecast origin 模擬真實預測情境；最新 run 使用 3 folds。

本地驗證結果

目前保留的完整 experiments：

Experiment	Validation	Features	Local MAE
`lgbm_v2`	holdout	337	0.6942
`xgb_v1`	holdout	337	0.7150
`lgbm_direct`	holdout	318	0.6770
`xgb_direct`	holdout	318	0.7320
`lean_v2`	rolling-origin	240	**0.1915**

`lean_v2` 是目前最新完整 run，但尚未用 Kaggle 驗證泛化。

Kaggle Public Leaderboard（40% 測試集資料）

方法 (Method)	Public MAE	洞見 (Insight)
Team 5 初始提交	**0.8094**	分數最佳，但需回查 leakage 風險
Team 5 Ensemble v1	**0.8232**	目前較乾淨、可重現的 baseline
Team 5 LGBM v2	**0.8299**	早期 two-stage 版本
Team 5 LGBM Direct	**0.8615**	local 好，但 LB 落差明顯
Team 5 Strategy B	**0.8640**	direct ensemble，泛化不足

下一個最值得驗證：`lgbm_gap_anomaly_regularized_lean_v2`。

系統工程進度

程式碼庫已經支援穩定迭代與結果追蹤：

- 核心腳本已模組化：`src/train.py`, `src/predict.py`, `src/features.py`。
- 已新增 `src/train_xgb.py` 與 `src/ensemble.py` 供模型比較與融合。
- 每次訓練保存 `config.json`、`metrics.json`、模型檔與 submission metadata。
- 已清理只有 `config.json`、沒有 metrics/model 的 incomplete runs。

目前 `experiments/latest.txt` 指向完整的 `lean_v2` run。

關鍵發現與挑戰 (Discoveries & Challenges)

- **Data leakage 風險**：隨機切分或不嚴格時間切分會讓 local MAE 過度樂觀。
- **Train-test discrepancy**：測試期沒有真實 `score`，不能直接套用近期 score lags。
- **Direct baseline 更乾淨**：LGBM direct local MAE 0.6770，但 Kaggle 為 0.8615。
- **Gap-aware score history 很有潛力**：`lean_v2` rolling-origin MAE 降到 0.1915。

目前重點是確認 `lean_v2` 的 Kaggle 泛化，而不是只相信 local MAE。

下一步 (Next Steps)

在 Deadline 之前，我們計畫：

- 用 `lean_v2` 產生 submission，並在保留 quota 的前提下上傳 Kaggle。
- 若 public MAE 改善，將 gap-aware score-history 設為主模型方向。
- 若 public MAE 未改善，檢查 rolling-origin split 是否仍有樂觀偏差。
- 補齊報告中的模型比較：direct LGBM、XGBoost、Ensemble、gap-aware features。

總結 (Summary)

目前已完成：

- 建立可重現的 direct forecasting pipeline 與 experiment tracking。
- 修正早期 train/test discrepancy 與 validation 設計問題。
- 實作 LightGBM、XGBoost、Ensemble 與 gap-aware score-history。
- Kaggle clean baseline: **0.8232**；最新 local candidate: **0.1915**。

接下來的重點：驗證 `lean_v2` Kaggle 表現，並整理成最終報告方法論。